

从 Bandit 到 RL: Deep Exploration 为何必要

即时信息、路径事件与 p^N 对 p

RL

Deep Exploration

Bandit

Posterior Sampling

Key Idea

Bandit 的反馈是单步事件：拉动一个 arm，立即得到该 arm 的奖励样本。RL 中的信息却可能位于一条轨迹的末端。此时，单步动作边缘分布不足以决定信息能否被观察；deep exploration 必须在策略层面组织动作的联合分布。

问题

探索通常被理解为一种交换：牺牲当前奖励，以减少对未知臂均值的不确定性。这个叙述在经典 bandit 中很自然：每次拉动一个 arm，都会直接产生一条关于它的反馈。因而，bandit 探索首先是一个 arm 选择问题。

RL 的区别不只是 horizon 更长。动作通过转移核改变未来状态的分布，也就改变了后续的状态-动作访问分布以及能收集到的观测。用 Osband et al. 的话说，deep exploration 不仅考虑即时信息增益，还要考虑一个动作会将智能体带向哪些后续学习机会 [1]。

这就产生了一个短视探索（myopic exploration）无法处理的现象：

$$\mathbb{E}[r_{t+1} \mid H_t, A_t = R] < 0, \quad I(\Theta; (S_{t+1}, r_{t+1}) \mid H_t, A_t = R) = 0,$$

但在有限学习时域内，Bayes 最优策略仍可能选择 R 。它不是在获取当前信息，而是在改变未来的状态访问，从而保留一个后续学习机会。

路径例子

Osband et al. 的 DeepSea 探索 MDP (Example 1) 提供了一个最小见证 [1]。每个 episode 的 horizon 为 N ；智能体从左上角出发，只有连续选择 R ，才能到达右下角的终止状态。终点类型在整个学习过程中固定为宝藏或炸弹；令其类型为

$$\Theta \in \{-1, +1\}, \quad \mathbb{P}(\Theta = +1) = \mathbb{P}(\Theta = -1) = \frac{1}{2}.$$

终点奖励的先验均值因此为零。沿对角线每向右一步还要支付 $0.01/N$ ，所以第一次完整到达终点的 Bayes 期望回报为 -0.01 。

关键在于中间转移：动作 R 不揭示 Θ ，却产生确定成本；同时，它增加了之后到达可提供信息的终止状态的概率。这正是即时信息增益与后续学习机会的分离。




图 1: 简化的 DeepSea MDP。中间转移与 Θ 无关；只有到达终止状态，智能体才能观察终点奖励。

简化 MDP

为了单独考察 deep exploration，先假设动作 R 的标签已知，并将原 MDP 压缩成图 1 中的确定性链。

Definition: 简化的 DeepSea MDP

固定深度 $N \geq 2$ 、路径总成本 $c \in (0, 1)$ ，以及未知但跨轮固定的参数

$$\Theta \in \{-1, +1\}, \quad \mathbb{P}(\Theta = +1) = \mathbb{P}(\Theta = -1) = \frac{1}{2}.$$

每轮从 s_0 开始。在 s_t , $0 \leq t < N$ ，动作 R 转移到 s_{t+1} 并支付 c/N ；动作 L 立即终止且之后收益为零。只有完成全部 N 个 R ，智能体才观察 Θ ，该轮总收益为 $\Theta - c$ 。

令 H_t 表示时刻 t 之前的历史。动作 a 的即时信息增益 (immediate information gain) 为

$$\text{IG}_t(a) := I(\Theta; (S_{t+1}, r_{t+1}) \mid H_t, A_t = a).$$

记 τ_N 为首次到达可提供信息的终止状态的时刻。给定后续策略 π ，相应的到达概率 (hitting probability) 为

$$h_t^\pi(a) := \mathbb{P}_\pi(\tau_N \leq N \mid H_t, A_t = a).$$

IG_t 只衡量单步反馈； h_t^π 则衡量在后续策略下到达可提供信息的状态的概率。

即时信息增益 $\neq$ 到达概率

当 $0 \leq t \leq N-2$ 时，下一步状态和成本都不依赖于 Θ ，因此

$$\text{IG}_t(R) = 0.$$

但若后续策略 π_p 在每一步独立地以概率 p 选择 R ，则

$$h_t^{\pi_p}(R) = p^{N-t-1} > 0, \quad h_t^{\pi_p}(L) = 0.$$

因而，若只看即时信息增益， R 似乎与探索无关；然而 R 确实改变了后续到达可提供信息的状态的概率。

考虑一个 explore-then-commit 策略：第一轮完整向右，此后仅当 $\Theta = +1$ 时重复该轨迹。它在前 T 轮内的 Bayes 期望回报为

$$-c + \frac{T-1}{2}(1-c).$$

它在 $T > (1+c)/(1-c)$ 时为正，因而严格优于始终选择 L 的零收益。因此，当前付出的成本不是为即时信息买单，而是在保留一个后续学习机会。

边缘与路径

固定每一步的动作边缘分布后，一个路径事件的概率还能改变多少？下面两种耦合抽象自 Osband et al. Example 1 与 Section 4 [1]。原文使用 $p = 1/2$ ；一般 p 与对所有耦合的优化是本文的初等扩展。

Theorem: 单步边缘分布不能决定路径事件 [1, Ex. 1, Sec. 4]

令 $X_t = 1$ 表示在一轮内的第 t 步选择 R ，并记 $G_N := \{X_1 = \dots = X_N = 1\}$ 。对固定的 $p \in (0, 1)$ ，令

$$\mathcal{C}_p := \{\mu \in \Delta(\{0, 1\}^N) : \mathbb{P}_\mu(X_t = 1) = p, \forall t\}$$

为具有相同 Bernoulli 边缘分布的所有耦合。则

$$\mathbb{P}_{\mu_{\text{prod}}}(G_N) = p^N, \quad \sup_{\mu \in \mathcal{C}_p} \mathbb{P}_\mu(G_N) = p.$$

共享样本耦合 $X_1 = \dots = X_N = Z$ 、 $Z \sim \text{Bern}(p)$ 达到上界。若各轮独立重采样，首次成功的期望轮数分别为 p^{-N} 与 p^{-1} 。

Proof. 对乘积耦合，独立性直接给出 $\mathbb{P}(G_N) = \prod_{t=1}^N \mathbb{P}(X_t = 1) = p^N$ 。

证明关键：在所有耦合中优化路径事件

对任意 $\mu \in \mathcal{C}_p$ 和任意 t ，都有 $G_N \subseteq \{X_t = 1\}$ ，因此

$$\mathbb{P}_\mu(G_N) \leq \mathbb{P}_\mu(X_t = 1) = p.$$

这个上界可以达到：只在每轮开始时采样 $Z \sim \text{Bern}(p)$ ，并令

$$X_1 = \dots = X_N = Z.$$

它保留所有边缘分布，而 $G_N = \{Z = 1\}$ ，故 $\mathbb{P}(G_N) = p$ 。关键不是增加随机性，而是在固定边缘分布下选择了对 G_N 最有利的耦合。

各轮独立时，首次成功时间服从参数为 $\mathbb{P}(G_N)$ 的几何分布，期望结论随即得到。 $\square$

$\mathcal{C}_p$ 中所有机制共享相同的动作边缘分布； p^N 对 p 比较的是乘积耦合与达到 Fréchet 上界的完全正相关耦合。**随机化的时间尺度只是实现方式，真正决定到达概率的是随机策略所诱导的轨迹分布。**




图 2: 相同边缘分布下：乘积耦合给出 p^N ；共享样本耦合达到上界 p 。

Bandit 与 RL

Bandit 与 RL 的分界不是是否“看长期”：UCB 和 Thompson sampling 也会为降低未来 regret 而探索。更本质的区别是：**bandit 动作没有延迟后果 (delayed consequences)**；**RL 动作通过状态转移改变后续的状态访问 [1]**。

无延迟后果与受控转移

在经典随机 bandit 中，选择 arm a_t 只决定当轮的奖励样本：

$$a_t \in \mathcal{A}, \quad r_{t+1} \sim P_\theta^{a_t}.$$

在 MDP 中，动作还会改变转移分布：

$$a_t \in \mathcal{A}(s_t), \quad s_{t+1} \sim P_\theta(\cdot \mid s_t, a_t).$$

因此， a_t 会改变未来的状态-动作访问分布，进而改变后续能观察到的奖励与转移。

在 bandit 中，“观察 arm a 的一次反馈”是单步事件 $\{A_t = a\}$ ；它的概率由当前动作边缘概率决定。DeepSea 中，“观察终点奖励”则是路径事件 G_N ；它的概率取决于整条动作序列的联合分布。受控转移把信息获取从一次局部采样变成了一个到达事件。

因此，动作 R 即使即时奖励为负、即时信息增益为零，仍可通过改变后续状态访问提高信息的可达性。Deep exploration 在策略层面处理不确定性：一次后验采样支配整轮的贪心策略，而不是在每一步独立地添加动作噪声。

Takeaway

Bandit exploration 主要把采样概率分配给各个 arm；RL exploration 还要把概率质量分配给能够到达可提供信息状态的策略或轨迹。探索的对象因而不只是动作边缘分布，而是它们经由转移诱导出的轨迹分布。

参考文献

[1] I. Osband, B. Van Roy, D. J. Russo, and Z. Wen. *Deep Exploration via Randomized Value Functions*. JMLR, 20(124):1–62, 2019. [PDF]