

Policy Gradient 的优化视角

从 RL 目标函数到 REINFORCE、PPO 与随机梯度收敛

Policy Gradient

RL

REINFORCE

PPO

Key Idea

Policy gradient 将强化学习中的策略搜索写成参数优化问题：

$$\max_{\theta} J(\theta), \quad J(\theta) := V^{\pi_{\theta}}(\rho).$$

其核心困难不在于形式上写出目标函数，而在于两点：一是动作来自策略采样，梯度必须通过轨迹分布估计；二是该估计通常具有高方差，因此算法行为同时受 RL 结构与 stochastic nonconvex optimization 控制。

Problem Formulation

定义 (discounted MDP).

考虑 discounted MDP

$$(\mathcal{S}, \mathcal{A}, P, r, \gamma, \rho),$$

其中 $P(s' | s, a)$ 为转移核， $r(s, a)$ 为奖励， $\gamma \in (0, 1)$ 为折扣因子， ρ 为初始状态分布。给定策略 π ，轨迹满足

$$\tau = (s_0, a_0, r_0, \dots), \quad a_t \sim \pi(\cdot | s_t).$$

目标函数为折扣回报

$$J(\pi) := \mathbb{E}_{\tau \sim \pi} \left[\sum_{t \geq 0} \gamma^t r(s_t, a_t) \right].$$

对固定策略 π ，定义

$$V^{\pi}(s) := \mathbb{E}_{\pi} \left[\sum_{t \geq 0} \gamma^t r_t \mid s_0 = s \right], \quad Q^{\pi}(s, a) := \mathbb{E}_{\pi} \left[\sum_{t \geq 0} \gamma^t r_t \mid s_0 = s, a_0 = a \right].$$

对参数化策略族 $\{\pi_{\theta}\}$ ，优化问题写为

$$J(\theta) = V^{\pi_{\theta}}(\rho) := \mathbb{E}_{s_0 \sim \rho} [V^{\pi_{\theta}}(s_0)].$$

Takeaway

离散动作中若采用 deterministic policy，例如

$$a = \arg \max_{a'} f_{\theta}(s, a'),$$

动作选择会随 θ 发生不连续切换，通常不可微或几乎处处梯度退化。随机策略 $\pi_{\theta}(a | s)$ 将动作选择转化为概率分布，从而使策略搜索可以使用梯度方法。

Policy Gradient Theorem

定义 discounted state visitation distribution

$$d_{\rho}^{\pi}(s) := (1 - \gamma) \sum_{t \geq 0} \gamma^t \mathbb{P}_{\pi}(s_t = s | s_0 \sim \rho).$$

在标准正则条件下，有

$$\nabla_{\theta} J(\theta) = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d_{\rho}^{\pi} \\ a \sim \pi_{\theta}(\cdot | s)}} [\nabla_{\theta} \log \pi_{\theta}(a | s) Q^{\pi_{\theta}}(s, a)].$$

该公式将对轨迹分布的求导转化为 score function

$$\nabla_{\theta} \log \pi_{\theta}(a | s),$$

是 REINFORCE、Actor-Critic、TRPO 和 PPO 的共同基础。

baseline and advantage

对任意只依赖状态的 $b(s)$,

$$\mathbb{E}_{a \sim \pi_{\theta}(\cdot | s)} [\nabla_{\theta} \log \pi_{\theta}(a | s) b(s)] = 0.$$

因此可将 $Q^{\pi}(s, a)$ 替换为

$$A^{\pi}(s, a) := Q^{\pi}(s, a) - V^{\pi}(s),$$

期望梯度不变，但方差通常下降。

REINFORCE and Stochastic Gradient

REINFORCE 以 sampled return

$$G_t := \sum_{k=t}^{T-1} \gamma^{k-t} r_k$$

估计 Q^π ，得到 Monte Carlo 更新

$$\theta \leftarrow \theta + \eta \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t.$$

该估计无偏但方差高；Actor-Critic 进一步用 critic 估计 V^π 或 A^π ，以一定 bias 换取较低 variance。

从优化角度看，policy gradient 更新可抽象为

$$\theta_{t+1} = \theta_t + \eta g_t, \quad \mathbb{E}[g_t | \theta_t] = \nabla J(\theta_t).$$

因此，在非凸情形中，常见保证不是全局最优性，而是 stationary measure：

$$\min_{0 \leq t < T} \mathbb{E} \|\nabla J(\theta_t)\|^2.$$

smoothness bound

若 J 为 β -smooth，且

$$\mathbb{E}[\|g_t - \nabla J(\theta_t)\|^2 | \theta_t] \leq \sigma^2,$$

则由 smoothness 得

$$\mathbb{E}[J_{t+1}] \geq \mathbb{E}[J_t] \left(\eta - \frac{\beta\eta^2}{2} \right) \mathbb{E} \|\nabla J_t\|^2 - \frac{\beta\eta^2\sigma^2}{2}.$$

telescoping 并令 $\Delta := J^* - J(\theta_0)$ ，得到

$$\min_{0 \leq t < T} \mathbb{E} \|\nabla J_t\|^2 \leq \frac{\Delta + \frac{\beta\eta^2\sigma^2 T}{2}}{T(\eta - \beta\eta^2/2)}.$$

Stepsize and PPO

令

$$x := \beta\eta, \quad A := \beta\Delta, \quad B := \frac{\sigma^2 T}{2}.$$

上界可写为

$$F(x) = \frac{A + Bx^2}{T(x - x^2/2)}.$$

在 $0 < x \leq 1$ 上，

$$\frac{x}{2} \leq x - \frac{x^2}{2} \leq x,$$

故 F 与

$$G(x) = \frac{A}{Tx} + \frac{B}{T}x$$

仅差常数因子。平衡两项得到

$$\hat{x} = \min \left\{ 1, \sqrt{\frac{A}{B}} \right\}, \quad \eta = \min \left\{ \frac{1}{\beta}, \sqrt{\frac{2\Delta}{\beta\sigma^2 T}} \right\}.$$

这里的 min 体现两种约束：步长不能超过 smoothness 允许的尺度，同时要平衡初始 gap 与随机方差。

PPO 仍基于 policy gradient，但通过 clipped surrogate 限制一次更新偏离旧策略的程度。
令

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}.$$

PPO 使用

$$L^{\text{clip}}(\theta) = \mathbb{E} \left[\min \{ r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \} \right].$$

clip 并未改变 policy gradient theorem；它约束 surrogate objective 的有效更新区间，避免用旧策略数据支持过远的新策略。

Summary

Takeaway

Policy gradient 的基本链条是

$$\text{MDP} \rightarrow J(\theta) = V^{\pi_\theta}(\rho) \rightarrow \nabla_\theta J(\theta) \rightarrow \theta_{t+1} = \theta_t + \eta g_t.$$

随机策略提供可微性，trajectory 提供梯度估计，优化理论解释噪声与步长。PPO 的核心不是新的梯度定理，而是在 noisy policy gradient 上加入保守的更新几何。

References

1. Sutton and Barto, *Reinforcement Learning: An Introduction*, 2nd ed., Ch. 13.
2. Williams, “Simple statistical gradient-following algorithms for connectionist reinforcement learning”, *Machine Learning*, 1992.
3. Sutton, McAllester, Singh, Mansour, “Policy Gradient Methods for Reinforcement Learning with Function Approximation”, NeurIPS, 1999.
4. Schulman et al., “Trust Region Policy Optimization”, ICML, 2015.
5. Schulman et al., “Proximal Policy Optimization Algorithms”, arXiv:1707.06347, 2017.