

相同的动作概率， 究竟说明了什么？

配套《从 Bandit 到 RL：Deep Exploration 为何必要》

读完一个漂亮的例子，最容易留下的未必是正确结论，而是一句稍微过强的概括。

在路径探索的例子中，每一步独立随机化，到达终点的概率可能随路径长度指数下降；整轮共享一次随机选择，则可能避免这个损失。但从这里走到“随机得更持久，探索就更有效”，还缺了什么？

下面三个问题分别改变条件信息、目标路径、未知量的持续性。目的不是重复计算一个概率，而是找出：哪一个条件变了，原来的解释就不能照用。

读者与使用方式

先修是联合分布、条件概率、期望，以及状态转移的基本含义。本样章可独立使用，无需先读配套笔记或原论文。

先完成第 1 至 2 页的问题，需要时逐层查看提示。解答从第 3 页开始。可以使用 AI，但先写下自己的判断，再核查它使用的条件；最后用自查句检查自己是否回答了问题。

1. 同样的边缘概率，是同样的策略吗？

考虑长度为 $N \geq 2$ 的确定性路径。每一步有 R, L 两个动作；只有连续选择 R 才到达终点。一次选择 L 后，本轮便不能再到该终点。为比较完整序列，仍定义本轮剩余时刻的动作。

令 $X_t = 1$ 表示第 t 步选择 R 。给定 $p \in (0, 1)$ ，比较两种生成机制：

- 独立随机化：各 X_t 独立，且服从 $\text{Bern}(p)$ ；
- 共享随机化：本轮开始时取 $Z \sim \text{Bern}(p)$ ，令所有 $X_t = Z$ 。

二者每个时刻都有 $\mathbb{P}(X_t = 1) = p$ 。一位读者据此说：

在每个状态，两种策略向右的概率相同；不同的只是抽随机数的次数。

这句话是否成立？请计算在已经连续向右 $t - 1$ 步之后，两种机制继续向右的条件概率，再解释路径成功概率的差距来自哪里。

2. 坚持一个动作，还是坚持一条路径？

现在将动作记为 0, 1，长度固定为四步。仍是确定性转移，但只有执行动作序列 1010 才能到达提供信息的终点。提前偏离该序列，本轮便不能到达它；所有动作与转移的对应关系都已知。

比较三种生成机制：

- 1. 每一步独立掷公平硬币；
- 2. 只掷一次公平硬币，整轮重复同一个动作；
- 3. 以相同概率在序列 1010 与 0101 中选一个，并执行完整序列。

证明三者每个时刻选择动作 1 的边缘概率均为 1/2，但到达目标终点的概率不同。然后修正这句话：

减少随机化频率，就能提高探索效率。

3. 更容易得到观测，就一定值得探索吗？

回到第一题的全向右路径。终点奖励是 $\Theta \in \{-1, +1\}$ ，先验各为 1/2。每向右一步付出 c/N ，其中 $0 < c < 1$ ；到达终点才观察到 Θ ，随后本轮结束。中间观测不依赖于它。始终选择 L 的回报为零。

比较两个环境：

- 固定环境：整个学习过程只抽一次 Θ ，所有轮共享它；
- 重抽环境：每轮开始独立抽取新的 Θ ，其取值在终点以前不可观察。

在固定环境中，先完整探索一次，此后仅在观察到宝藏时重复该路径。在 T 轮内，这个策略何时优于始终选择 L ？

在重抽环境中，前两题的路径概率计算仍可成立。它们能否据此证明探索有正的决策价值？请说明过去的终点观测究竟能帮助预测什么。

分层提示

题	提示一	提示二
1	区分“第 t 步”与“已经走到目标路径的第 t 步”。	用条件概率的乘法公式；共享机制中，第一个动作揭示了什么？
2	列出每种机制支持哪些完整序列。	比较 0000/1111 与 1010/0101；两者都只在开头随机一次。
3	分开计算探索轮和利用轮。	若本轮未知量与所有过去记录独立，昨天的宝藏还预测今天的宝藏吗？

解答与关键判断

1. 边缘相同，沿途条件概率不同

令 $G_N = \{X_1 = \dots = X_N = 1\}$ 。两种机制的成功概率分别为 p^N 与 p 。这个比较是对 Osband et al. (2019, Example 1) 路径例子的初等抽象；一般 p 的表述来自配套 note，不是原论文的一般 RL 效率定理。[1]

关键一步：把无条件边缘概率换成沿目标路径的条件概率。

由乘法公式，

$$\mathbb{P}(G_N) = \mathbb{P}(X_1 = 1) \prod_{t=2}^N \mathbb{P}(X_t = 1 \mid X_1 = \dots = X_{t-1} = 1).$$

独立机制中，每一项仍为 p 。共享机制中，已知 $X_1 = 1$ 就知道 $Z = 1$ ，所以后续条件概率全为 1。于是两种乘积分别为

$$p \cdot p \cdots p = p^N, \quad p \cdot 1 \cdots 1 = p.$$

在这个确定性路径模型中，位于目标路径的中间状态就意味着此前全向右。因此，“每个时刻向右的无条件概率相同”并不意味着“到达同一个中间状态后向右的概率相同”。共享机制把更多概率放在一旦开始就继续走完的序列上。

原来的读者判断把时间边缘分布误当成了给定历史的动作分布。若给定同一环境和初始分布，两种机制在每个可达历史下都有相同的条件动作分布，逐步展开轨迹概率便得到相同的轨迹分布；此时不会出现这里的差距。

自查 若只写出了 p^N 与 p ，还没有回答题目。需要指出在“此前全向右”这一条件下，继续向右的概率分别是 p 和 1。

2. 随机化时间尺度不指定目标

三种机制的各时刻边缘分布均为公平硬币。第二种由 0000 与 1111 各占一半；第三种由两条逐位互补的序列各占一半，因此边缘结论成立。

机制	有正概率的完整序列	到达 1010
逐步独立	所有 16 条序列，各占 1/16	1/16
重复同一动作	0000, 1111，各占 1/2	0
选择完整序列	1010, 0101，各占 1/2	1/2

关键构造：后两种机制的随机化时刻完全相同，结果却不同。

区别在于一次随机选择决定的是哪种动作序列。时间一致性没有告诉我们，所选序列是否通向信息。

更准确的判断是：在这个确定性例子中，需要把概率分配给能到达目标的动作序列。一般 MDP 中，对应的对象是策略及其诱导的轨迹分布；“采样一个策略”不能被替换成“整轮重复一个动作”。这里的第三种机制也不是通用探索算法：它已经利用了题目给定的目标路径结构。

自查 “多坚持”和“少掷硬币”都不能解释为什么第二种失败、第三种成功；必须指出被赋予概率的路径不同。

3. 观测的价值取决于它能改变哪些后续决策

固定环境中，第一轮期望回报为 $-c$ ，此后以概率 $1/2$ 得知环境是宝藏，并在每个后续轮获得 $1 - c$ 。总 Bayes 期望回报为

$$-c + \frac{T-1}{2}(1-c),$$

它严格为正，当且仅当 $T > (1+c)/(1-c)$ 。例如 $c = 0.01$ 时，两轮便足以使该策略的期望回报为正。这只比较所述策略与零回报基线，不声称给出了所有策略的完整最优性证明。

重抽环境中，令 Θ_j 为第 j 轮终点类型， E_j 为该轮到达终点的事件， $C_j \geq 0$ 为该轮路径成本。由于终点之前没有本轮类型的信号，转移已知且不依赖于它，任何基于可观察历史和独立内部随机数的策略，其 E_j 都与 Θ_j 独立。因此

$$\begin{aligned}\mathbb{E}[\Theta_j \mathbf{1}_{E_j} - C_j] &= \mathbb{E}[\Theta_j] \mathbb{P}(E_j) - \mathbb{E}[C_j] \\ &= -\mathbb{E}[C_j] \leq 0.\end{aligned}$$

关键条件是跨轮独立，而不是终点难不难到达。

观察本轮类型之后，本轮已经结束；下一轮类型重新独立抽取。该观测不能改善下一轮的预测。在所述模型内，始终选择 L 达到零回报，探索没有正的期望收益。

路径概率刻画得到一条观测的机会；它本身没有证明这条观测有助于未来决策。固定环境中的一次发现可以反复利用，重抽环境中则不能。这也说明， p^N 与 p 的差距不是一个脱离环境假设的 regret 结论。

自查 正确解释需要同时提到：本轮结束后才知道类型、下一轮类型独立重抽、没有其他持续未知参数可供学习。仅说“奖励期望为零”不够，因为固定环境的先验均值也为零。

带到下一篇论文的三个问题

读到“某种随机化改善探索”时，先写清楚：

1. 比较中固定的是无条件动作边缘、给定历史的策略，还是别的对象？
2. 哪个轨迹事件会带来需要的观测？提出的方法为何给它足够概率？
3. 这条观测揭示什么未知量，又会改变哪一个后续决策？

这三个问题分别检查概率比较、环境结构和信息价值。它们不是一般算法的充分条件，但足以阻止把一个漂亮例子误读成过强的保证。

参考与范围

[1] I. Osband, B. Van Roy, D. J. Russo, Z. Wen. *Deep Exploration via Randomized Value Functions*. JMLR, 20(124):1–62, 2019. [论文网页](#) / [原文 PDF](#)。

本样章承接公开 note 的路径抽象：动作与转移的对应关系已知，只有终点类型未知。原论文 DeepSea 例子还包含未知的动作编号与方向映射；中间转移可能揭示这些映射，因此本文的“没有即时信息”始终限于终点类型，不能推广为没有任何 MDP 信息。第二题的交替路径与第三题的重抽环境是为检查结论边界而构造的变式，不是原论文的结论。全文未复现原论文的算法分析或 regret bound。