

从 Bandit 到 RL: Deep Exploration 为何必要

同样的单步随机性，为何产生不同的探索效率？

RL

Deep Exploration

Bandit

Posterior Sampling

Key Idea

Bandit 的反馈是单步事件：拉动一个 arm，立即得到该 arm 的奖励样本。RL 中的信息却可能位于一条轨迹的末端。此时，单步动作边缘分布不足以决定信息能否被观察；deep exploration 必须在策略层面组织动作的联合分布。

问题

如果一个算法在每一步都保留尝试未知动作的机会，它是否就能有效探索？在经典 bandit 中，这个直觉有直接的依据：选择一个 arm，就得到它的一次奖励样本。探索可以牺牲当前奖励，但通常不必先完成一串没有信息的动作，才能获得所需反馈。

RL 的区别不只是 horizon 更长。动作通过转移核改变未来状态的分布，也就改变了后续的状态-动作访问分布以及能收集到的观测。用 Osband et al. 的话说，deep exploration 不仅考虑即时信息增益，还要考虑一个动作会将智能体带向哪些后续学习机会 [1]。

这就产生了一个短视探索（myopic exploration）无法处理的现象：

$$\mathbb{E}[r_{t+1} \mid H_t, A_t = R] < 0, \quad I(\Theta; (S_{t+1}, r_{t+1}) \mid H_t, A_t = R) = 0,$$

但在有限学习时域内，Bayes 最优策略仍可能选择 R 。它不是在获取当前信息，而是在改变未来的状态访问，从而保留一个后续学习机会。

路径例子

取 Osband et al. 的 DeepSea 例子 (Example 1) 的一个简化版本 [1]：先令动作标签与左右方向的对应关系已知，只保留终点奖励的不确定性。每轮长度为 N ；智能体从起点出发，只有连续选择 R ，才能到达目标终点。终点类型在整个学习过程中固定为宝藏或炸弹；令其类型为

$$\Theta \in \{-1, +1\}, \quad \mathbb{P}(\Theta = +1) = \mathbb{P}(\Theta = -1) = \frac{1}{2}.$$

终点奖励的先验均值因此为零。沿对角线每向右一步还要支付 $0.01/N$ ，所以第一次完整到达终点的 Bayes 期望回报为 -0.01 。

关键在于中间转移：动作 R 不揭示 Θ ，却产生确定成本；同时，它增加了之后到达可提供信息的终止状态的概率。这正是即时信息增益与后续学习机会的分离。




图 1: 简化的 DeepSea MDP。中间转移与 Θ 无关；只有到达终止状态，智能体才能观察终点奖励。

简化 MDP

图 1 将目标路径压缩成确定性链。原例子还包含未知的动作映射，中间转移可以帮助学习这些映射；这里的“没有即时信息”只针对未知的终点类型 Θ 。

Definition: 简化的 DeepSea MDP

固定深度 $N \geq 2$ 、路径总成本 $c \in (0, 1)$ ，以及未知但跨轮固定的参数

$$\Theta \in \{-1, +1\}, \quad \mathbb{P}(\Theta = +1) = \mathbb{P}(\Theta = -1) = \frac{1}{2}.$$

每轮从 s_0 开始。在 s_t , $0 \leq t < N$ ，动作 R 转移到 s_{t+1} 并支付 c/N ；动作 L 立即终止且之后收益为零。只有完成全部 N 个 R ，智能体才观察 Θ ，该轮总收益为 $\Theta - c$ 。

令 H_t 表示时刻 t 之前的历史。动作 a 的即时信息增益 (immediate information gain) 为

$$\text{IG}_t(a) := I(\Theta; (S_{t+1}, r_{t+1}) \mid H_t, A_t = a).$$

记 τ_N 为首次到达可提供信息的终止状态的时刻。给定后续策略 π ，相应的到达概率 (hitting probability) 为

$$h_t^\pi(a) := \mathbb{P}_\pi(\tau_N \leq N \mid H_t, A_t = a).$$

IG_t 只衡量单步反馈； h_t^π 则衡量在后续策略下到达可提供信息的状态的概率。

即时信息增益 $\neq$ 到达概率

给定仍在目标路径上的历史 H_t ，当 $0 \leq t \leq N-2$ 时，下一步状态和成本都不依赖于 Θ ，因此

$$\text{IG}_t(R) = 0.$$

但若后续策略 π_p 在每一步独立地以概率 p 选择 R ，则

$$h_t^{\pi_p}(R) = p^{N-t-1} > 0, \quad h_t^{\pi_p}(L) = 0.$$

因而，若只看即时信息增益， R 似乎与探索无关；然而 R 确实改变了后续到达可提供信息的状态的概率。

考虑一个 explore-then-commit 策略：第一轮完整向右，此后仅当 $\Theta = +1$ 时重复该轨迹。它在前 T 轮内的 Bayes 期望回报为

$$-c + \frac{T-1}{2}(1-c).$$

它在 $T > (1+c)/(1-c)$ 时为正，因而严格优于始终选择 L 的零收益。因此，当前付出的成本不是为即时信息买单，而是在保留一个后续学习机会。

边缘与路径

固定每一步的动作边缘分布后，一个路径事件的概率还能改变多少？下面将 Osband et al. Example 1 与 Section 4 的探索机制抽象成已知路径上的概率比较 [1]。一般 p 与所有耦合上的上界是本文的初等推导，不是原论文的算法定理。提前终止时，补齐未执行的动作以定义完整序列；这不改变到达事件。

Theorem: 单步边缘分布不能决定路径事件 [1, Ex. 1, Sec. 4]

令 $X_t = 1$ 表示在一轮内的第 t 步选择 R ，并记 $G_N := \{X_1 = \dots = X_N = 1\}$ 。对固定的 $p \in (0, 1)$ ，令

$$\mathcal{C}_p := \{\mu \in \Delta(\{0, 1\}^N) : \mathbb{P}_\mu(X_t = 1) = p, \forall t\}$$

为具有相同 Bernoulli 边缘分布的所有耦合。则

$$\mathbb{P}_{\mu_{\text{prod}}}(G_N) = p^N, \quad \sup_{\mu \in \mathcal{C}_p} \mathbb{P}_\mu(G_N) = p.$$

共享样本耦合 $X_1 = \dots = X_N = Z$ 、 $Z \sim \text{Bern}(p)$ 达到上界。若各轮独立重采样，首次成功的期望轮数分别为 p^{-N} 与 p^{-1} 。

Proof. 对乘积耦合，独立性直接给出 $\mathbb{P}(G_N) = \prod_{t=1}^N \mathbb{P}(X_t = 1) = p^N$ 。

证明关键： 在所有耦合中优化路径事件

对任意 $\mu \in \mathcal{C}_p$ 和任意 t ，都有 $G_N \subseteq \{X_t = 1\}$ ，因此

$$\mathbb{P}_\mu(G_N) \leq \mathbb{P}_\mu(X_t = 1) = p.$$

这个上界可以达到：只在每轮开始时采样 $Z \sim \text{Bern}(p)$ ，并令

$$X_1 = \dots = X_N = Z.$$

它保留所有边缘分布，而 $G_N = \{Z = 1\}$ ，故 $\mathbb{P}(G_N) = p$ 。关键不是增加随机性，而是在固定边缘分布下选择了对 G_N 最有利的耦合。

各轮独立时，首次成功时间服从参数为 $\mathbb{P}(G_N)$ 的几何分布，期望结论随即得到。 $\square$

差距来自哪里？把路径概率按条件展开：

$$\mathbb{P}(G_N) = \mathbb{P}(X_1 = 1) \prod_{t=2}^N \mathbb{P}(X_t = 1 \mid X_1 = \dots = X_{t-1} = 1).$$

独立机制中，沿途每一项仍为 p ；共享机制中，一旦第一个动作向右，后续条件概率就都为 1。因此比较的是 $p \cdot p \cdots p$ 与 $p \cdot 1 \cdots 1$ 。**相同的时间边缘分布，不等于给定同一历史的动作分布相同**。若后者也相同，在同一环境中就会诱导相同的轨迹分布。

随机化的时间尺度本身不保证探索效率；还要看被赋予概率的轨迹是否通向信息。这里的 p^{-N} 与 p^{-1} 只刻画首次到达已知路径终点的轮数，并非原 DeepSea 中学习未知动作映射的复杂度。




图 2: 相同边缘分布下：乘积耦合给出 p^N ；共享样本耦合达到上界 p 。

Bandit 与 RL

Bandit 与 RL 的分界不是是否“看长期”：UCB 和 Thompson sampling 也会为降低未来 regret 而探索。更本质的区别是：**bandit 动作没有延迟后果 (delayed consequences)**；**RL 动作通过状态转移改变后续的状态访问 [1]**。

无延迟后果与受控转移

在经典随机 bandit 中，选择 arm a_t 只决定当轮的奖励样本：

$$a_t \in \mathcal{A}, \quad r_{t+1} \sim P_{\theta}^{a_t}.$$

在 MDP 中，动作还会改变转移分布：

$$a_t \in \mathcal{A}(s_t), \quad s_{t+1} \sim P_{\theta}(\cdot | s_t, a_t).$$

因此， a_t 会改变未来的状态-动作访问分布，进而改变后续能观察到的奖励与转移。

在 bandit 中，“观察 arm a 的一次反馈”是单步事件 $\{A_t = a\}$ ；它的概率由当前动作边缘概率决定。DeepSea 中，“观察终点奖励”则是路径事件 G_N ；它的概率取决于整条动作序列的联合分布。受控转移把信息获取从一次局部采样变成了一个到达事件。

因此，动作 R 即使即时奖励为负、即时信息增益为零，仍可通过改变后续状态访问保留学习机会。后验采样提供一种实现：用一次采样的价值函数决定整轮的贪心策略，使跨时间的动作服务于同一个可能环境下的回报目标。它不是要求整轮重复同一个动作，也不是 deep exploration 的唯一定义。

Takeaway

Bandit exploration 主要把采样概率分配给各个 arm；RL exploration 还要把概率质量分配给能够到达可提供信息状态的策略或轨迹。探索的对象因而不只是动作边缘分布，而是它们经由转移诱导出的轨迹分布。

参考文献

[1] I. Osband, B. Van Roy, D. J. Russo, and Z. Wen. *Deep Exploration via Randomized Value Functions*. JMLR, 20(124):1–62, 2019. [\[PDF\]](#)